

Detecção de falsificações faciais

Acertar não é o mesmo que explicar.

Resultados do benchmark espacial–espectral e uma extensão para comparar explicações.

Lucas Cunha · Lucas Sotomaior · Lucas Gasperin
Beatriz Caldas · Eduardo Pianovski · Rayson Laroca
Pontifícia Universidade Católica do Paraná

DUAS LIDERANÇAS

0,884

Xception · teste limpo

0,726

DINOv3 · degradado

O que está sendo comparado

6

famílias de modelos

CNNs, transformers e DINOv3

181.947

imagens no teste

Comparação limpa e degradada

3

**sementes por
configuração**

Médias reportadas no estudo


ROC-AUC

0,50: referência aleatória · 1,00: separação perfeita

A degradação muda o ranking

● Teste limpo

■ Teste degradado



Pequena queda, sozinha, não é robustez

DINOv3 congelado

LIMPO

0,809

DEGRADADO

0,726

Queda absoluta

0,083 AUC

ViT do zero

LIMPO

0,624

DEGRADADO

0,608


Queda absoluta

0,016 AUC

Compare o nível de desempenho e a queda — não apenas a estabilidade.

Frequência: complemento, não substituição

Três contrastes reportados no teste degradado



Ganhos descritivos em AUC; não demonstram qual artefato foi aprendido.

O que os resultados permitem concluir

OBSERVAÇÃO

O ranking muda.

Há queda sob degradação e ganhos em algumas entradas híbridas.

INTERPRETAÇÃO

A causa não está isolada.

Arquitetura, pré-treinamento e pistas visuais ainda precisam ser separados.

Um mapa plausível não é, por si só, uma explicação fiel.

Três perguntas para explicar as decisões

01

Mesmas imagens

Como as arquiteturas explicam os mesmos acertos e erros?

02

RGB e frequência

As explicações mudam quando muda o domínio de entrada?

03

Falhas compartilhadas

Que condições aparecem quando todos os modelos do grupo erram?

Comparações controladas; nenhum resultado de heatmap é antecipado.

Tarefa 1 · As mesmas 64 imagens

VP

16

Falsa prevista falsa

FN

16

Falsa prevista real

VN

16

Real prevista real

FP

16

Real prevista falsa

64

Mesmas identidades.
Mesma ordem.
Todos os modelos.

O equilíbrio 16×4 vale para o modelo de referência, não para todos simultaneamente.

Tarefa 2 · Comparar no domínio correto

ESPACIAL

Onde na imagem?

Pixels da imagem RGB.
Atribuição sobre a entrada espacial.

FREQUÊNCIA

Quais frequências?

Coeficientes do espectro.
Atribuição sobre a entrada espectral.

Um agrupamento no espectro não é uma localização no rosto.

Tarefa 3 · Falhas do conjunto declarado

01 · ALINHAMENTO

Validar

Mesmas imagens, rótulos e predições completas.

02 · INTERSEÇÃO

Encontrar

Imagens erradas por todos os checkpoints declarados.

03 · CONTROLE

Comparar

Revisão humana cega e controles pareados por rótulo.

Falha compartilhada não significa vulnerabilidade universal.

12 métodos, perguntas diferentes

GRADIENTES / LOCALIZAÇÃO

Grad-CAM
Integrated Gradients
Gradient SHAP
Saliency
Input $\times$ Gradient
SmoothGrad

PERTURBAÇÃO / MODELOS LOCAIS

Kernel SHAP
LIME
Occlusion
Feature Ablation
Shapley Value Sampling

ATENÇÃO

Attention Rollout

Agnóstico à classe.
Não equivale a uma
atribuição da decisão.

Alvo fixo nas atribuições de classe: logit falso menos logit real.

O que está pronto e o que falta medir

IMPLEMENTADO

Amostras e seleção reproduzíveis
Métodos e exportação de mapas
Rastreabilidade e retomada
Controles e cobertura

AINDA A MEDIR

Galerias de mapas reais
Comparações RGB–frequência
Análise dos casos compartilhados
Associações com condições visuais

A literatura e o código orientam hipóteses; os dados decidem os resultados.

Três mensagens para levar

01 Robustez muda o ranking.

A melhor média no teste limpo não garante liderança após degradação.

02 Frequência pode complementar RGB.

Ganhos reportados motivam investigar as pistas realmente utilizadas.

03 Explicabilidade exige controle.

Mesmas imagens, alvos fixos, domínios corretos e falhas bem definidas.

Apoio · Tabela completa dos resultados RGB

Configuração anterior	Limpo	Degradado	Queda em AUC
Xception · do zero	0,884	0,609	0,275
ResNet-18 · do zero	0,846	0,635	0,211
MobileNetV3 · do zero	0,839	0,594	0,245
ViT · do zero	0,624	0,608	0,016
CLIP-style · do zero	0,750	0,619	0,131
DINOv3 · congelado	0,809	0,726	0,083

Diferenças das médias arredondadas; não representam significância estatística.

Fontes e material de apoio

A Estudo anterior

Cunha et al. · Tabela III e seção IV

B Manuscrito de seis páginas

Resultados anteriores e protocolos

C Guia e configuração

Execução, artefatos e limites

D Integrated Gradients

Sundararajan et al. · ICML 2017

E Grad-CAM

Selvaraju et al. · ICCV 2017

F Sanity Checks for Saliency Maps

Adebayo et al. · NeurIPS 2018

G Quantus

Hedström et al. · JMLR 2023